

多任务的应用 综述

王祥通

2018226215015

Abstract

首先介绍多任务的定义, 必要性, 以及遇到的挑战。然后, 本文从理论上回顾现有工作的理论研究, 包括对多任务以软硬共享方法进行的分类方法。最后, 本文以视觉任务下多任务学习进行分类, 主要包括场景感知的密集估计型和场景监测的非密集估计型两种。前者在多任务研究领域有较多的参考, 后者由于任务的抽象程度更高, 工作较少, 也是本文的重点。

1. 多任务学习中的任务关系 (基于视觉)

多任务学习中的任务, 在不同的情况下意义不同, 有时是代表不同尺度或者视觉层次的相同任务[1], 有时是代表一个视觉任务的不同阶段[2], 有时也代表不同种类的视觉任务[?]. 本文根据应用, 将多任务分成两个分支, 分别是以场景感知为主, 模型多数为密集估计 (Dense Prediction) 的多任务集合, 以及以场景监测为主, 模型多数为稀疏估计的多任务集合。

1.1. 场景感知类任务集

在场景感知类任务集中, 重点处理对象为场景的背景, 即全局性感知, 涉及任务包括深度估计[?, ?], 场景表面法向估计[3], 边缘检测[4], 光流估计[?, ?, ?], 语义分割[?, 5], 视觉里程计[6], 自运动速度估计[7]任务, 图.1 和图.2 分别是两个任务以及四个任务下的多任务学习框架, 可以看到每个子任务通过几何关系耦合在一起, 并企图提升各自任务的效果。

此类任务的一个特点就是数据难以标注, 人工处理困难极大等。例如, 光流任务是要估计出图像中每个像素的移动, 并通过色彩映射标注出来, 以此估计相对相机视角下每个点的运动状况, 但此种任务无法直接标注。此类任务的另一个特点就是耦合关系较强, 各个任务之间的层次性较弱。文献[8, 9]主要介绍了此类任务集的耦合关系, 并量化了两两任务之间的关联度, 并且还在[10]中基于前面的工作提出了如何鲁棒学习的策略, 使得模型的泛化能力更好。

以上任务多数都是基于视觉导航类的任务需求, 重点在探测场景感知环境上, 相机一般是运动状态, 算法一般搭载在机器人上, 计算资源有限, 与场景监测类任务有着较大的不同。

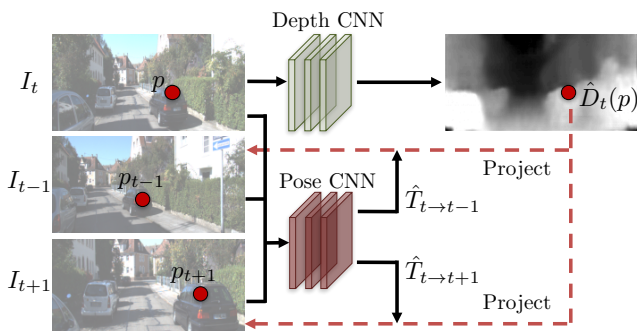


图 1. 基于深度估计任务与相机自运动位姿变换两个任务下的框图[6]




图 2. 包含了深度估计, 位姿变换, 分割以及光流估计四个任务的框图[?]

1.2. 场景监测类任务集

在场景监测类任务集中, 重点处理对象是场景中的物体, 即局部性感知, 涉及任务包括物体检测, 跟踪, 运动轨迹预测, 实例分割, 物体位姿估计等。该任务集中的子任务抽象程度较高, 没有明显的关系来关联, 因此相关研究较为空白。此类任务的特点之一就是相比于场景感知类任务的数据, 标注较为容易。第二个特点是此类任务的关键难点, 也是本文研究的重点, 即任务之间的耦合性并非通过几何耦合这类数学关系体现, 而是通过逻辑关系, 各个任务之间的层次性较强。因此, 本文根据不同的视觉任务以及层次关系, 我们将该任务集绘制如图.3

在场景检测类视觉任务衍生出的应用级任务中, 人脸检测以精度要求高, 难度较大, 应用前景广阔收到更大的关注。由于需要在大量人脸中准确分别, 所以一些人脸检测应用中引入了更多辅助任务以增强性

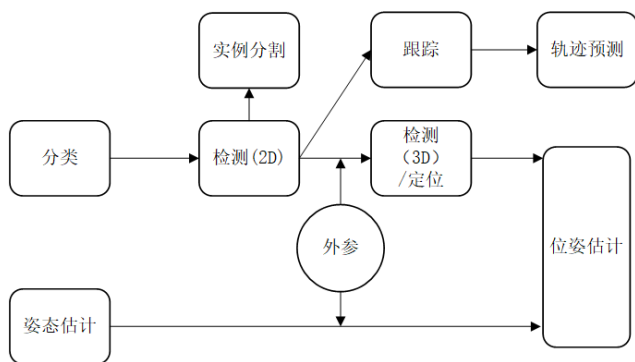


图 3. 非密集估计类任务层次关系

能。Zhang等人[2]提出通过堆叠式多重网络来进行该任务，对人脸分类、锚箱回归、面部特征点定位作为三个任务，并分别通过网络各自进行任务。但此种方法的任务实质上是一个应用级视觉任务的不同阶段，子任务的结果无法直接拿来应用，与之前提及的任务有本质不同。同样是人脸识别任务，Ranjan等人[11]则零任务集中包含了人脸检测、关键点定位、人脸姿态估计以及性别识别四个子任务，效果如图.4




图 4. HyperFace效果展示，可见程序的结果包含人脸检测（框出）、脸部关键点定位（绿点）、性别识别（红蓝色框）以及姿态估计（俯仰偏转翻滚角度）。

2. 多任务学习外的范式关系

MTL 与机器学习中的其他学习范式相关，包括迁移学习 [12]、多标签学习 [13] 和多输出回归等。在第1章中，我们讨论了多任务学习内，任务的关系，本章则讨论多任务学习范式与其他学习范式之间的关系。

2.1. 迁移学习范式

MTL 的设置类似于迁移学习的设置，但有显著差异。在 MTL 中，不同任务之间没有区别，目标是提高所有任务的性能。然而，迁移学习是在源任务的帮助下提高目标任务的性能，因此目标任务比源任务起着更重要的作用。总之，MTL 对所有任务一视同仁，但在迁移学习中，目标任务最受关注。从知识流的角度来看，迁

移学习中的知识转移流是从源任务到目标任务，但在多任务学习中，任何一对任务之间都有知识共享的流。持续学习[14]，其中任务依次来，一个一个地学习任务，而MTL是一起学习多个任务。在多标签学习和多输出回归中，每个数据点都与多个标签相关联，这些标签可以是分类的或数字的。如果我们将所有可能的标签都视为一个任务，那么多标签学习和多输出回归在某种意义上可以看作是多任务学习的一个特例，其中不同的任务在训练和训练期间总是共享相同的数据。

2.2. 监督学习范式

在大多数应用中，标记数据的收集成本很高，但未标记的数据却很丰富。因此，在一些 MTL 应用中，每个任务的训练数据集由标记数据和未标记数据组成，因此我们希望利用未标记数据中包含的有用信息来进一步提高监督学习任务的性能。在机器学习中，半监督学习和主动学习是利用未标记数据的两种方式，但方式不同。半监督学习旨在利用未标记数据中包含的几何信息，而主动学习则选择具有代表性的未标记数据来查询预言机，希望尽可能少地增加标记成本。因此，半监督学习和主动学习可以与 MTL 结合，产生三种新的学习范式，包括半监督多任务学习 [15, 16, 17]、多任务主动学习 [18, 19, 20] 和半监督多任务主动学习 [21]。具体而言，[15, 16] 中提出了一种半监督多任务分类模型，使用随机游走来利用每个任务中的未标记数据，然后通过宽松的狄利克雷过程对多个任务进行聚类。在 [17] 中，提出了一种用于回归任务的半监督多任务高斯过程，其中不同的任务通过所有任务的高斯过程中的内核参数的超先验相关联，将未标记的数据合并到设计中每个任务中的核函数，以在相应的功能空间中实现平滑。与这些半监督多任务方法不同，多任务主动学习为多任务学习者自适应地选择信息丰富的未标记数据，因此选择标准是核心研究问题。Richard等人。[18] 相信要选择的数据实例应该为一组任务提供尽可能多的信息，而不是只有一个任务，因此他们提出了两种用于多任务主动学习的协议。在 [19] 中，预期误差减少用作标准，其中每个任务都由监督的潜在狄利克雷分配模型建模。受平衡开发和探索之间权衡的多臂老虎机的启发，[20] 中提出了一种选择策略，以考虑基于轨迹范数正则化的多任务学习器的风险和相应的置信度边界。在 [22] 中，提出的泛化界限用于从多个未标记的任务中选择一个子集来获取标签，以提高所有任务的泛化性能。对于半监督多任务主动学习，Li 等人。[21] 提出了一个模型，使用 Fisher 信息作为标准来选择未标记的数据以获取它们的标签，其中半监督多任务分类模型 [15, 16] 作为每个任务的分类器。

2.3. 无监督学习范式

MTL 不仅在监督学习任务中实现了性能提升，而且在聚类等无监督学习任务中也实现了性能提升。在 [23] 中，提出了一种基于单任务 Bregman 聚类的多任务 Bregman 聚类方法，通过使用推土机距离来最小化任何一对任务之间在聚类中心方面的距离，然后在 [24, 25]，[23] 的改进版本及其内核扩展被提出，通过在单任务和任务 Bregman 聚类之间选择更好的一个来避免 [23]

中的正则化器造成的负面影响. 在 [26] 中, 提出了一种多任务内核 k -means 方法, 它通过任意一对任务之间的 MMD 和有助于识别平滑内核空间的拉普拉斯正则化来学习内核矩阵. 在 [27] 中, 提出的两种多任务聚类方法是 MTFL 和 MTRL 方法的扩展, 将标签视为要学习的聚类指标. 在 [28] 中, MTL 的原理通过捕获数据实例之间的相关性被纳入子空间聚类. 在 [29] 中, 提出了一种属于基于实例的 MTL 的多任务聚类方法, 以在不同任务之间共享数据实例. 在 [30] 中, 提出了一种多任务谱聚类算法, 该算法可以通过线性函数处理样本外问题来学习聚类分配, 通过实现任务间的特征选择 $\ell_{2,1}$ 正则化 [31]. [32] 建议识别任务集群结构并一起学习任务关系.

2.4. 强化学习范式

强化学习 (RL) 是机器学习中一个很有前途的领域, 并且在许多应用程序中表现出卓越的性能, 例如游戏 (例如 Atari 和围棋) 和机器人技术. MTL 可以帮助提高强化学习的性能, 从而实现多任务强化学习 (MRL). 具体来说, 在 [33] 中, 任务解决一系列马尔可夫决策过程 (MDP), 使用分层贝叶斯无限混合模型对 MDP 上的分布进行建模, 并且对于每个新的 MDP, 以前学习的分布用作信息事先的. 在 [34] 中, 引入了区域化策略表示来表征每个任务中代理的行为, 并将 Dirichlet 过程放置在跨多个任务的区域化策略表示上, 以对任务进行聚类. 在 [35] 中, 每个任务都使用高斯过程时间差值函数模型, 分层贝叶斯方法是对不同任务中值函数的分布进行建模.

2.5. 稀疏学习范式

卡兰德列洛等人. [36] 假设不同任务中的值函数的参数向量是联合稀疏的, 然后使用 $\ell_{2,1}$ 正则化和 MTFL 方法扩展 MTFS 方法以一起学习多个任务中的值函数. 在 [37] 中, 提出了一种将每个子任务与模块化子策略相关联的模型, 以从策略草图中学习, 该模型用命名子任务序列注释任务, 并提供有关任务之间高级结构关系的信息. 在 [38] 中, 提出了一个多任务线性可解 MDP, 其任务基础矩阵包含所有任务共享的组件任务库, 用于维护任务的并行分布式表示, 每个任务都使代理能够利用宏动作同时进行. 在 [39] 中, 基于注意力的多任务深度强化学习模型可以自动将任务分组到状态级粒度的子网络中. 在 [40] 中, 引入了一个共享经验框架, 以使用特定于任务的奖励来识别定义为共享区域的相似部分, 这些部分可以指导任务策略的经验共享. 在 [41] 中, 多任务软选项学习, 一种基于规划作为推理的分层框架, 通过共享先验进行正则化, 以避免训练不稳定, 并允许在不忘记学习策略的情况下微调新任务的选项. 压缩和蒸馏的概念已被纳入 MRL, 如 [42, 43, 44, 45]. 例如, 在 [42] 中, 提议的 Actor-Mimic 方法结合了深度强化学习和模型压缩技术来训练一个可以学习为多个任务采取行动的策略网络. 在 [43] 中, 提出了一种策略蒸馏方法, 不仅可以训练一个有效的网络来学习代理的策略, 还可以将多个特定于任务的策略合并为一个策略. 在 [44] 中, 通过将分散的单任务策略提炼为跨多个任务的统一策略来解决部分可观察性下的多任务多智能体强化学习

问题. 在 [45] 中, 每个任务都有自己的策略, 该策略被限制为接近由蒸馏训练的共享策略. MRL 中的一些作品 [46, 47, 48, 49, 50, 51] 侧重于在线和分布式设置. 具体来说, 在 [46] 中, 设计了一个分布式 MRL 框架, 将其建模为普遍共识的实例, 并开发了一个高效的分散式求解器. 在 [47, 48] 中, 通过主动采样更难的任务, 在不需要专家监督的在线设置中学习多个目标导向的任务. 在 [49] 中, 开发了一个分布式代理, 不仅可以在单机训练中更有效地使用资源, 而且可以在不牺牲数据效率或资源利用率的情况下扩展到数千台机器. [50] 从变分推理的角度制定了 MRL, 它提出了一种具有二次收敛保证的新型分布式求解器. 在 [51] 中, 提出了一种在线学习算法来动态组合不同的辅助任务, 这些辅助任务提供梯度方向以加速主要强化学习任务的训练. 一些著作研究了 MRL 的理论基础. 例如, 在 [52] 中, 任务之间的共享表示通过理论保证进行分析, 以突出共享表示的条件, 并将近似值迭代的有限时间范围扩展到多任务设置. 此外, 还有一些工作可以设计新颖的 MRL 方法. 例如, 在 [53] 中, 提出了一个 MRL 框架来训练代理使用分层策略来决定何时使用以前学习的策略以及何时使用时间语法学习新技能, 帮助代理学习复杂的时间依赖性. [54] 研究多个顺序决策任务的并行学习问题, 并提出自动调整每个任务对代理更新的贡献, 使所有任务对学习动态具有可比的影响. 在 [55] 中, 提出了一种用于多任务深度强化学习的自监督表示学习算法, 以基于未来观察的多步预测表示来捕获有关环境动态的结构化信息.

2.6. 多视图学习

多视图学习假设每个数据点都与多组特征相关联, 其中每组特征对应一个视图, 它通常利用多个视图中包含的信息进行监督或半监督学习任务. 多任务多视图学习将多视图学习扩展到 MTL 设置, 其中每个任务都是多视图学习问题. 具体来说, 在 [56] 中, 针对多任务多视图分类问题提出了一种基于图的方法. 在一个任务中, 每个视图都被强制要求与其他视图和标签保持一致, 而不同的任务期望对它们共享的视图有相似的预测, 使视图成为构建任务相关性的桥梁. 在 [57] 中, 正则化的 MTL 方法 [58] 和 MTRL 方法都应用于不同任务的每个视图, 并且任务中的不同视图期望在未标记数据上达成一致. 与研究多任务多视图分类问题的 [56, 57] 不同, 在 [59, 60] 中, 提出了两种多任务多视图聚类方法, 这两种方法都考虑了三个因素: 视图任务聚类, 对任务中的每个视图进行聚类, 视图关系学习, 最大限度地减少任务中视图之间的分歧, 以及低秩结构学习, 旨在学习公共视图下不同任务的共享子空间. 这两种方法的区别在于, 第一种方法对非负数据采用二部图共聚类方法, 而另一种采用半非负矩阵三分解对一般数据进行聚类. 在 [61] 中, 提出了一种多标签多视图算法, 不仅可以通过 $\ell_{2,1}$ 正则化学习共同特征, 还可以通过 Frobenius 范数识别无用的视图. 在多任务多视图学习中, 每个任务通常都提供有标记和未标记的数据, 因此这种范式也可以看作是另一种利用未标记信息进行 MTL 的方式. [62] 提出了一种深度多任务多视图模型来融合基于十字绣网络的所有视图.

参考文献

- [1] Iasonas Kokkinos. Ubertnet: Training a universal convolutional neural network for low-, mid-, and high-level vision using diverse datasets and limited memory. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6129–6138, 2017. 1
- [2] Kaipeng Zhang, Zhanpeng Zhang, Zhifeng Li, and Yu Qiao. Joint face detection and alignment using multitask cascaded convolutional networks. *IEEE Signal Processing Letters*, 23(10):1499–1503, 2016. 1, 2
- [3] Wei Yin, Yifan Liu, Chunhua Shen, and Youliang Yan. Enforcing geometric constraints of virtual normal for depth prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 5684–5693, 2019. 1
- [4] Zhenheng Yang, Peng Wang, Yang Wang, Wei Xu, and Ram Nevatia. Lego: Learning edge with geometry all at once by watching videos. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 225–234, 2018. 1
- [5] Marvin Klingner, Jan-Aike Termohlen, Jonas Mikolajczyk, and Tim Fingscheidt. Self-supervised monocular depth estimation: Solving the dynamic object problem by semantic guidance. In *European Conference on Computer Vision*, pages 582–600. Springer, 2020. 1
- [6] Tinghui Zhou, Matthew Brown, Noah Snavely, and David G. Lowe. Unsupervised learning of depth and ego-motion from video. In *CVPR*, 2017. 1
- [7] Vitor Guizilini, Rares Ambrus, Sudeep Pillai, Allan Raventos, and Adrien Gaidon. 3d packing for self-supervised monocular depth estimation. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020. 1
- [8] Amir R Zamir, Alexander Sax, William Shen, Leonidas J Guibas, Jitendra Malik, and Silvio Savarese. Taskonomy: Disentangling task transfer learning. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3712–3722, 2018. 1
- [9] Trevor Standley, Amir Zamir, Dawn Chen, Leonidas Guibas, Jitendra Malik, and Silvio Savarese. Which tasks should be learned together in multi-task learning. In *International Conference on Machine Learning*, pages 9120–9132, 2020. 1
- [10] Amir R Zamir, Alexander Sax, Nikhil Cheerla, Rohan Suri, Zhangjie Cao, Jitendra Malik, and Leonidas J Guibas. Robust learning through cross-task consistency. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11197–11206, 2020. 1
- [11] Rajeev Ranjan, Vishal M Patel, and Rama Chellappa. Hyperface: A deep multi-task learning framework for face detection, landmark localization, pose estimation, and gender recognition. *IEEE transactions on pattern analysis and machine intelligence*, 41(1):121–135, 2017. 2
- [12] Qiang Yang, Yu Zhang, Wenyan Dai, and Sinno Jialin Pan. *Transfer Learning*. Cambridge University Press, 2020. 2
- [13] Min-Ling Zhang and Zhi-Hua Zhou. A review on multi-label learning algorithms. *IEEE TKDE*, 2014. 2
- [14] German Ignacio Parisi, Ronald Kemker, Jose L. Part, Christopher Kanan, and Stefan Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019. 2
- [15] Qiuhua Liu, Xuejun Liao, and Lawrence Carin. Semi-supervised multitask learning. In *NIPS*, 2007. 2
- [16] Qiuhua Liu, Xuejun Liao, Hui Li, Jason R. Stack, and Lawrence Carin. Semisupervised multitask learning. *IEEE TPAMI*, 2009. 2
- [17] Yu Zhang and Dit-Yan Yeung. Semi-supervised multi-task regression. In *ECMLPKDD*, 2009. 2
- [18] Roi Reichart, Katrin Tomanek, Udo Hahn, and Ari Rapoport. Multi-task active learning for linguistic annotations. In *ACL*, 2008. 2
- [19] Ayan Acharya, Raymond J. Mooney, and Joydeep Ghosh. Active multitask learning using both latent and supervised shared topics. In *SDM*, 2014. 2
- [20] Meng Fang and Dacheng Tao. Active multi-task learning via bandits. In *SDM*, 2015. 2
- [21] Hui Li, Xuejun Liao, and Lawrence Carin. Active learning for semi-supervised multi-task learning. In *ICASSP*, 2009. 2
- [22] Anastasia Pentina and Christoph H. Lampert. Multi-task learning with labeled and unlabeled tasks. In *ICML*, 2017. 2
- [23] Jianwen Zhang and Changshui Zhang. Multitask Bregman clustering. In *AAAI*, 2010. 2
- [24] Xianchao Zhang and Xiaotong Zhang. Smart multi-task Bregman clustering and multi-task kernel clustering. In *AAAI*, 2013. 2
- [25] Xianchao Zhang, Xiaotong Zhang, and Han Liu. Smart multitask Bregman clustering and multitask kernel clustering. *ACM TKDD*, 2015. 2
- [26] Quanquan Gu, Zhenhui Li, and Jiawei Han. Learning a kernel for multi-task clustering. In *AAAI*, 2011. 3
- [27] Xiao-Lei Zhang. Convex discriminative multitask clustering. *IEEE TPAMI*, 2015. 3
- [28] Yu Wang, David P. Wipf, Qing Ling, Wei Chen, and Ian J. Wassell. Multi-task learning for subspace segmentation. In *ICML*, 2015. 3
- [29] Xianchao Zhang, Xiaotong Zhang, and Han Liu. Self-adapted multi-task clustering. In *IJCAI*, 2016. 3
- [30] Yang Yang, Zhigang Ma, Yi Yang, Feiping Nie, and Heng Tao Shen. Multitask spectral clustering by exploring inter-task correlation. *IEEE TCYB*, 2015. 3
- [31] Xiaofeng Zhu, Xuelong Li, Shichao Zhang, Chunhua Ju, and Xindong Wu. Robust joint graph sparse coding for unsupervised spectral feature selection. *IEEE TNNLS*, 2017. 3
- [32] Xiaotong Zhang, Xianchao Zhang, Han Liu, and Jiebo Luo. Multi-task clustering with model relation learning. In *IJCAI*, 2018. 3
- [33] Aaron Wilson, Alan Fern, Soumya Ray, and Prasad Tadepalli. Multi-task reinforcement learning: A hierarchical Bayesian approach. In *ICML*, 2007. 3

- [34] Hui Li, Xuejun Liao, and Lawrence Carin. Multi-task reinforcement learning in partially observable stochastic environments. *JMLR*, 2009. 3
- [35] Alessandro Lazaric and Mohammad Ghavamzadeh. Bayesian multi-task reinforcement learning. In *ICML*, 2010. 3
- [36] Daniele Calandriello, Alessandro Lazaric, and Marcello Restelli. Sparse multi-task reinforcement learning. In *NIPS*, 2014. 3
- [37] Jacob Andreas, Dan Klein, and Sergey Levine. Modular multitask reinforcement learning with policy sketches. In *ICML*, 2017. 3
- [38] Andrew M. Saxe, Adam Christopher Earle, and Benjamin Rosman. Hierarchy through composition with multitask LMDPs. In *ICML*, 2017. 3
- [39] Timo Bräm, Gino Brunner, Oliver Richter, and Roger Wattenhofer. Attentive multi-task deep reinforcement learning. In *ECMLPKDD*, 2019. 3
- [40] Tung-Long Vuong, Do Van Nguyen, Tai-Long Nguyen, Cong-Minh Bui, Hai-Dang Kieu, Viet-Cuong Ta, Quoc-Long Tran, and Thanh Ha Le. Sharing experience in multitask reinforcement learning. In *IJCAI*, 2019. 3
- [41] Maximilian Igl, Andrew Gambardella, Nantas Nardelli, N. Siddharth, Wendelin Böhmer, and Shimon Whiteson. Multi-task soft option learning. In *UAI*, 2020. 3
- [42] Emilio Parisotto, Jimmy Ba, and Ruslan Salakhutdinov. Actor-mimic: Deep multitask and transfer reinforcement learning. In *ICLR*, 2016. 3
- [43] Andrei A. Rusu, Sergio Gomez Colmenarejo, Çağlar Gülçehre, Guillaume Desjardins, James Kirkpatrick, Razvan Pascanu, Volodymyr Mnih, Koray Kavukcuoglu, and Raia Hadsell. Policy distillation. In *ICLR*, 2016. 3
- [44] Shayegan Omidshafiei, Jason Pazis, Christopher Amato, Jonathan P. How, and John Vian. Deep decentralized multi-task multi-agent reinforcement learning under partial observability. In *ICML*, 2017. 3
- [45] Yee Whye Teh, Victor Bapst, Wojciech M. Czarnecki, John Quan, James Kirkpatrick, Raia Hadsell, Nicolas Heess, and Razvan Pascanu. Distral: Robust multitask reinforcement learning. In *NIPS*, 2017. 3
- [46] Salam El Bsar, Haitham Bou-Ammar, and Matthew E. Taylor. Scalable multitask policy gradient reinforcement learning. In *AAAI*, 2017. 3
- [47] Sahil Sharma and Balaraman Ravindran. Online multi-task learning using active sampling. In *ICLR Workshop*, 2017. 3
- [48] Sahil Sharma, Ashutosh Kumar Jha, Parikshit Hegde, and Balaraman Ravindran. Learning to multi-task by active sampling. In *ICLR*, 2018. 3
- [49] Lasse Espeholt, Hubert Soyer, Rémi Munos, Karen Simonyan, Volodymyr Mnih, Tom Ward, Yotam Doron, Vlad Firoiu, Tim Harley, Iain Dunning, Shane Legg, and Koray Kavukcuoglu. IMPALA: scalable distributed deep-RL with importance weighted actor-learner architectures. In *ICML*, 2018. 3
- [50] Rasul Tutunov, Dongho Kim, and Haitham Bou-Ammar. Distributed multitask reinforcement learning with quadratic convergence. In *NeurIPS*, 2018. 3
- [51] Xingyu Lin, Harjatin Singh Baweja, George Kantor, and David Held. Adaptive auxiliary task weighting for reinforcement learning. In *NeurIPS*, 2019. 3
- [52] Carlo D'Eramo, Davide Tateo, Andrea Bonarini, Marcello Restelli, and Jan Peters. Sharing knowledge in multi-task deep reinforcement learning. In *ICLR*, 2020. 3
- [53] Tianmin Shu, Caiming Xiong, and Richard Socher. Hierarchical and interpretable skill acquisition in multi-task reinforcement learning. In *ICLR*, 2018. 3
- [54] Matteo Hessel, Hubert Soyer, Lasse Espeholt, Wojciech Czarnecki, Simon Schmitt, and Hado van Hasselt. Multi-task deep reinforcement learning with PopArt. In *AAAI*, 2019. 3
- [55] Zhaohan Guo, Bernardo Avila Pires, Mohammad Gheshlaghi Azar, Bilal Piot, Florent Altché, Jean-Bastien Grill, and Remi Munos. Bootstrap latent-predictive representations for multitask reinforcement learning. In *ICML*, 2020. 3
- [56] Jingrui He and Rick Lawrence. A graph-based framework for multi-task multi-view learning. In *ICML*, 2011. 3
- [57] Jintao Zhang and Jun Huan. Inductive multi-task learning with multiple view data. In *KDD*, 2012. 3
- [58] Theodoros Evgeniou, Charles A. Micchelli, and Massimiliano Pontil. Learning multiple tasks with kernel methods. *JMLR*, 2005. 3
- [59] Xianchao Zhang, Xiaotong Zhang, and Han Liu. Multi-task multi-view clustering for non-negative data. In *IJCAI*, 2015. 3
- [60] Xiaotong Zhang, Xianchao Zhang, Han Liu, and Xinyue Liu. Multi-task multi-view clustering. *IEEE TKDE*, 2016. 3
- [61] Xiaofeng Zhu, Xuelong Li, and Shichao Zhang. Block-row sparse multiview multilabel learning for image classification. *IEEE TCYB*, 2016. 3
- [62] Lecheng Zheng, Yu Cheng, and Jingrui He. Deep multi-modality model for multi-task multi-view learning. In *SDM*, 2019. 3